AI Agent Harness Engineering

从技术扩散到知识蒸馏：让通用 AI 安全落地于利基市场

Presenter Name

小型内部学术交流

2026 年 4 月 11 日

AI 模型进步与技术扩散的鸿沟

能力侧的爆发

- GPT-4、Claude、Codex 等在编码、推理、创作上表现惊人
- 模型智商快速提升，但“技术扩散”并未自动发生
- 消费市场与利基市场（niche markets）仍难以直接受益

利基市场的困境

- 需要编程能力但无力负担专职程序员
- 流程高度非标，容错空间有限
- 缺少测试、审计、回滚等互补性资本

关键问题

不是 AI 不够聪明，而是 AI 缺乏在特定场景中安全、可靠、可扩展运行的基础设施。

通用性的诅咒：为何通用模型在特定场景中反而脆弱

人类是“特化 LLM”

- 人类专家接受的信息分布极窄但极深
- 拥有领域直觉与生物 reward 驱动的注意力过滤
- 科学家在各自领域的表现远胜通用模型

通用模型的弱点

- Transformer 全连接注意力易被无关信息稀释
- “鸭子划水”式干扰会降低回答准确率
- 擅长模式匹配，但缺乏“什么不做”的边界意识

结论：通用性是一把双刃剑。没有场景化的约束与过滤，通用 AI 的可靠性反而下降。

根本差异：好奇心机制 vs. 工具响应设计

人类：主动探索的特化引擎

- 人类具有**好奇心驱动的信息收集 reward 机制**
- 多巴胺、成就感、社会认同促使个体主动深耕某一领域
- 从通用婴儿成长为特化专家：这是**自发**的自我塑造过程
- 结果是产生不可复制的 tacit knowledge 与领域直觉

当前 AI：被动的工具响应体

- LLM 的设计逻辑是**响应用户指令**，而非主动探索世界
- 没有内在的"我想知道更多"驱动力，上下文严格受限
- 即使给予再长的 context，也不会自发地"想要"深入某一领域
- 永远是通用模式匹配，**不会自动特化**

结论：Harness Engineering 的一个隐性使命，正是用结构化的信息流转（skills、workspace、memory）来补偿 AI 缺失的主动深耕机制，模拟人类的特化过程。

范式演进：从 Prompt Engineering 到 Harness Engineering

阶段	时间	核心问题	类比
Prompt Engineering	2022–2024	优化单次指令与“魔法短语”	口头下命令
Context Engineering	2024–2025	RAG、记忆、上下文动态管理	提供文档和手册
Harness Engineering	2025+	构建约束、反馈、运行时与工具链	建造带质检与安全的办公室

核心共识

$$\text{Agent} = \text{Model} + \text{Harness}$$

模型是引擎，Harness 是底盘、刹车、传动与安全系统。

Harness Engineering 的定义：不只是工具链

传统误解

Harness 只是“给 AI 加约束”或“封装 API 调用”。

更精确的定义

Harness Engineering 是在**概率性决策层**与**确定性执行层**之间，构建可验证、可回滚、可审计的接口层。

Control

约束与规范：`AGENTS.md`、linter、类型检查、测试作为契约。

Agency

工具与接口：MCP 服务器、子 Agent 委派、权限边界、沙箱。

Runtime

执行与恢复：生命周期 hook、重试/回滚、trace 收集。

张力 I：解放执行 vs. 审计拥塞

AI 降低了执行门槛

- 一小时可生成数百行代码或执行数十个任务
- 利基市场不再需要专职程序员

但审计带宽没有同比增加

若所有输出都需人眼审批，人类将成为系统瓶颈。疲劳导致形式化审批，安全形同虚设。

出路：风险分层治理

- **低风险**：纯自动化验证（linter + diff），人仅在异常时介入
- **中风险**：自动验证 + 审计日志，人按需抽查
- **高风险**：强制 human-in-the-loop

Harness 的核心价值不是“辅助人类审”，而是**用确定性规则替代人类审**。

张力 II：通用模型 vs. 特化需求

问题的根源

通用 LLM 的注意力权重被海量弱相关模式稀释，在特定场景中反而不如“特化人类”。

工程补偿

Harness 通过**上下文隔离**与**渐进式披露**，帮通用模型“人工特化”。

关键技术

- **Sub-agent 隔离**：将不相关子任务剥离出主上下文
- **Progressive disclosure**：详细规则按需加载，避免一次性 dump
- **Context firewall**：关键操作前清空闲聊历史，只保留必要状态

本质：用工程化的结构弥补通用模型在特定场景下的“特化不足”。

历史启示：芯片 EDA 工具链与人类 Harness

芯片行业的先例

芯片开发成本极高，因此每家芯片公司都有专门的工具与流程开发团队。这些 EDA harness 是数十年 tape-out 失败积累的组织知识，是保证复杂系统可制造性的核心资产。

AI Harness 的额外挑战

- 芯片 harness 建立在**确定性验证**之上（bit-exact 测试、形式化验证）
- AI harness 的底层是概率性 LLM，**不可形式化验证**
- 同样的 prompt，模型提供者可能在后台更新权重，导致行为漂移

给我们的教训

- 可靠工具链需要长时间验证累积
- 但 AI harness 还需应对**底层黑箱腐蚀**
- 这不是 AI 独有的缺陷，而是所有系统的普遍规律

腐蚀、维护与复用：Harness 的生命周期

Harness 不是一劳永逸的

底层模型漂移、场景需求变化、外部环境演进，都会侵蚀依赖 LLM 行为假设的软规则。**世事无常，万事皆会回归熵增**。

人类的价值：注入负熵

- 持续维护软规则（prompt template、意图解析逻辑）
- 监控行为漂移，更新风险分层
- 将新的边缘案例编码进 harness

人类的最大价值：复用

- 将一次投入的智慧烧炼为可持久、可复用的结构
- 在多处场景中复用同一 harness，降低边际成本
- **复用**是人类对抗熵增的最高效方式

过渡形态之辩与认知资本的刚性

一种常见的反驳

“未来模型足够强大后，我们今天煞费苦心构建的 harness 都会变得多余。”

回应：树叶随树干同步上移

- 过去 harness 处理“写代码”，未来处理“代码如何与组织的合规流程、数据 schema、安全策略集成”
- 只要 AI 还在操纵文件系统、访问网络、与人类协作，**可审计性与责任归属**就是永恒需求
- 物质计算成本的下降，不等于互补性资本（流程梳理、安全审计、持续维护）的同步消失

灰暗但诚实的洞察

- **认知资本的刚性不可逃避**：AI 不会让灰姑娘变成白雪公主
- Harness 只能赋能已具备某种最低限度认知资本的个体或组织
- 对于那些连“描述清楚自己的需求”都做不到的人，AI + harness 依然遥不可及

关键不是成本，而是收益：一个 harness 的维护成本再高，只要其带来的价值增量足以覆盖投入，它就是可持续的。

隐藏的陷阱：基础工作的消失与隐形门槛

一个反直觉的悖论

- AI 接管了大量基础执行工作（代码草拟、文献检索、格式整理）
- 表面上降低了入行门槛，但实际上**剥夺了基础训练的机会**
- 人类失去了在重复劳作中建立“手感”与 tacit knowledge 的过程

后果：虚假的熟练

- 人们看似能快速产出复杂成果，但缺乏对底层机制的真正理解
- 当 AI 犯错或触及边界情况时，无法判断、无法纠正
- 正如过度依赖计算器的小学生更难发展出数学直觉

Harness 的回应方向

不是阻止人类接触基础工作，而是通过**风险分层**和**关键节点强制介入**，确保人类仍然“机会性地”参与到足以维持判断力的基础修正中，防止认知能力的系统性退化。

案例：ScholarAIO 作为垂直 Harness

系统定位

ScholarAIO 是一个学术研究全流程的 Agent Harness，围绕 Claude Code 构建，覆盖文献检索、阅读、分析与写作。

知识蒸馏的具象化

将“研究者如何读文献、做笔记、写综述”这一原本只能由导师言传身教数年才能内化的**隐性实践知识**，蒸馏为一组可复用的结构与规则。

自省

ScholarAIO 自身也面临同样的批评：它能**加速**已有基础的研究者，但对尚未建立学术规范的新手，可能同样导致“虚假的熟练”。

核心组件

- `.claude/skills/`：封装科研任务的 Skill 体系
- `MEMORY.md` / `notes.md`：持久化记忆与跨会话知识传承
- `workspace/`：工作区隔离，防止上下文污染
- `data/` 目录结构：L1–L4 分层加载与数据生命周期管理

分层 Harness 与软硬规则的边界

上层：软规则（需求解析、异常分类、意图理解）

↓

中层：接口层（prompt 模板、sub-agent 编排、上下文防火墙）

↓

下层：硬规则（沙箱、权限检查、审计日志、回滚机制）

关键原则

不允许软规则直接触发作不可逆的硬动作。

结论：Harness Engineering 的真正价值

不是简单的“让每个人都能用 AI”

- 那会导致审计拥塞与责任风险的不成比例转移
- 利基市场没有足够的人力来做高密度审计
- 灰姑娘不会变成白雪公主：**认知资本的刚性不可逃避**

而是“让具备基础的人通过验证好的 Harness 安全调用 AI”

- 把通用 AI 能力**特化**到具体场景
- 将行业经验**蒸馏**为可持久、可复用的规则与结构
- 在概率与确定之间建立可扩展的**缓冲层**

更完整的图景

通用 AI 是**树干**，提供基础的生命力与可能性；Harness Engineering 是**树叶**，将这股生命力分化成适应无数具体场景的特化结构。树干越高，树叶的生态位也越往上移。Harness 的可持续性不取决于其绝对维护成本，而取决于它所带来的**边际收益能否覆盖边际投入**。我们的目标并非覆盖所有利基市场，而是为那些**已具备最低限度认知资本、但缺乏技术执行资源**的个体与组织，提供一条从想法到可靠实现的通道。Harness Engineering 不仅是技术基础设施，更是知识形态学与学术资本的传承机制。